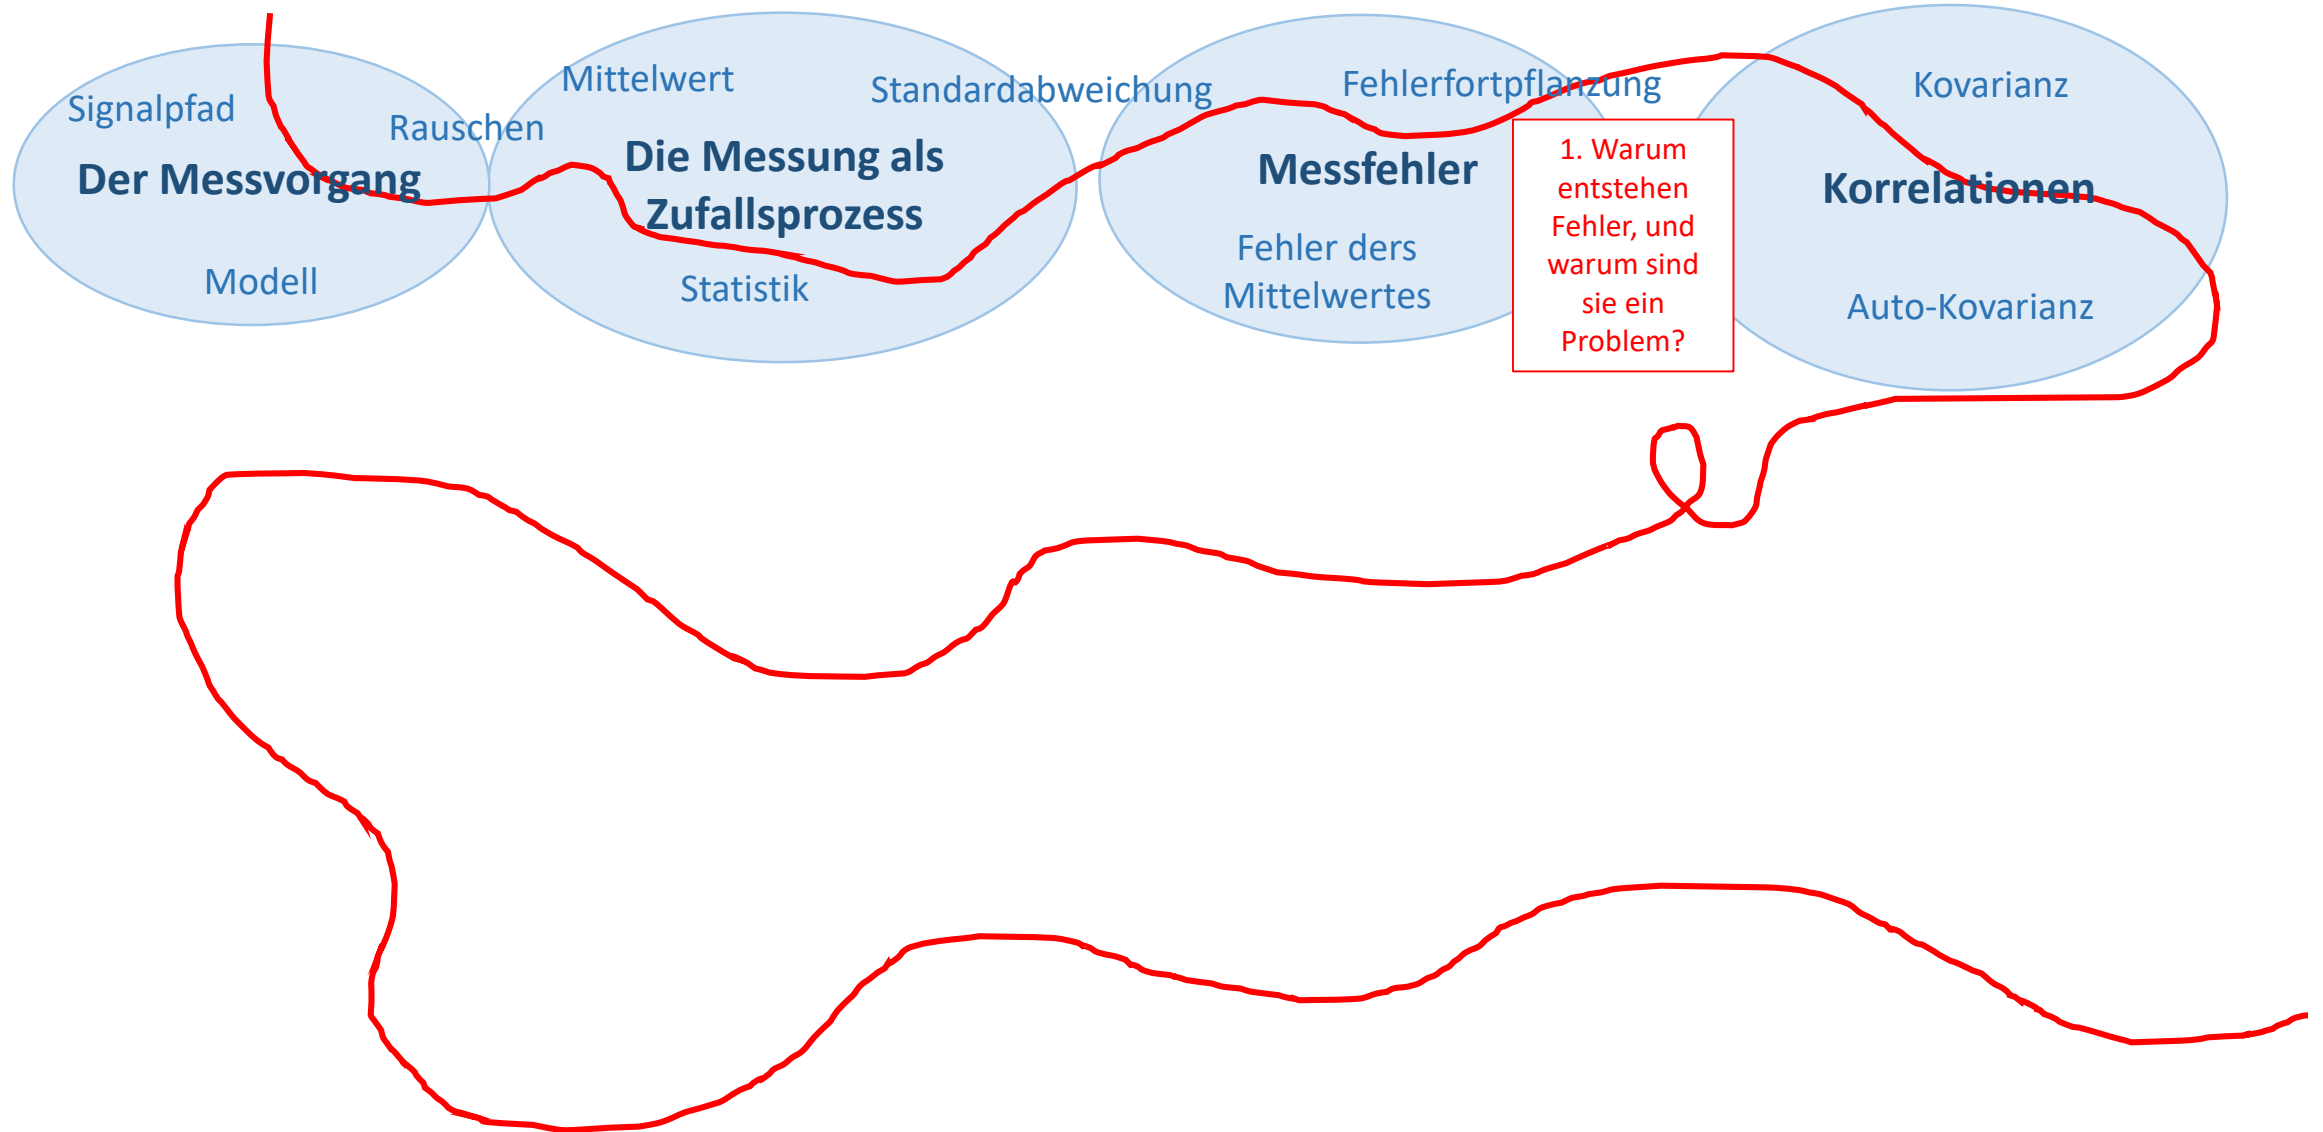


# Kovarianz und Auto-Kovarianz

# Der rote Faden: wie erhalte ich aussagekräftige Zahlen aus komplexen Daten?



## **Themen dieser Vorlesung:**

- Wie erkennen wir Korrelationen zwischen Messgrößen?
- Korrelation und Kausalität
- Auto-Kovarianz

# Repetition zu Messfehlern


- In einem Experiment tauchen zwei Quellen von statistischen Fehlern auf ( $\sigma_x$  und  $\sigma_y$ ). Unter welchen Bedingungen kann der gemessene Fehler  $\sigma_f^2$  kleiner sein als die gewichtete Summe der einzelnen Fehlerquellen wie in der Gauss-Fehlerfortpflanzung berechnet?

$$\sigma_f^2 = \left( \frac{\partial \bar{f}}{\partial x} \right)^2 \sigma_x^2 + \left( \frac{\partial \bar{f}}{\partial y} \right)^2 \sigma_y^2 + 2 \frac{\partial \bar{f}}{\partial x} \frac{\partial \bar{f}}{\partial y} \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$$



Resultat für unkorrelierte Variablen

Kovarianz  $\sigma_{xy}^2$

Die Varianz des Messfehlers  $\sigma_f^2$  kann kleiner sein als die Summe der Varianzen  $\sigma_{x,y}^2$ , wenn der Kovarianzterm negativ ist.




# Korrelierte Messgrößen



Die Frequenz und die Temperatur zeigen ähnliche Verläufe – die beiden Variablen sind **korreliert**.

Ich weiss dadurch noch nicht, ob und in welche Richtung eine Kausalität besteht!

# Korrelierte Messgrößen





**Q** Wie kann Korrelation anschaulich erklärt und mathematisch formuliert werden?

Korrelation bedeutet, dass eine Änderung in einer Variablen ( $x$ ) mit einer proportionalen Änderung in der anderen Variablen ( $y$ ) einhergeht.

Mathematisch kann ich eine Änderung (relativ zum Mittelwert als Bezugspunkt) mit  $x - \bar{x}$  beschreiben. Der Ausdruck  $(x_n - \bar{x})(y_n - \bar{y})$  sollte also entweder immer positiv oder negativ sein. Wir sprechen dann von positiver oder negativer Korrelation.

# Korrelierte Messgrößen



$$\frac{cov(f, T)}{\sigma_f \sigma_T} = 0.9995$$

## Kovarianz

$$\sigma_{xy}^2 = cov(x, y) = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$$

## Korrelationskoeffizient

$$\rho_{xy} = \frac{cov(x, y)}{\sigma_x \sigma_y} \in [-1, 1] \quad \textbf{Normiert!}$$

$\rho_{xy} = 0$  unkorrelierte Variablen



$\rho_{xy} = \pm 1$  maximal (anti-)korrelierte Variablen

➡ für  $y = ax$

## Kovarianz-Matrix

$$\begin{pmatrix} \sigma_x^2 & \sigma_{xy}^2 & \dots \\ \sigma_{yx}^2 & \sigma_y^2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}$$

# Korrelierte Messgrößen



## Kovarianz

Wir betrachten die nichtlineare Funktion  $y = x^2$ , wobei  $x$  eine Zufallsvariable mit einer *symmetrischen Verteilungsfunktion* sei (d.h.  $-x$  ist gleich wahrscheinlich wie  $x$ ).

**Q Welches Resultat erhalten wir hier für die Kovarianz?**

Wir erhalten die Kovarianz 
$$\text{cov}(x, y) = \frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$$

$= 0$  da  $\frac{1}{N} \sum_{n=1}^N y_n = \bar{y}$

$$= \frac{1}{N} \sum_{n=1}^N x_n (y_n - \bar{y}) - \bar{x} \left( \frac{1}{N} \sum_{n=1}^N (y_n - \bar{y}) \right)$$


$$= \frac{1}{N} \sum_{n=1}^N x_n (x_n^2 - \bar{y}) = \frac{1}{N} \sum_{i=1}^N x_n^3 - \frac{1}{N} \sum_{n=1}^N x_n \bar{y} = 0$$

Für  $N \rightarrow \infty$  da nur ungerade Ordnungen von  $x$

**Die Kovarianz ist nur für lineare Korrelationen vorgesehen, nichtlineare Fälle müssen generell anders behandelt werden**




# Korrelierte Messgrößen



Elektrische oder magnetische Felder im Labor,  
Luftfeuchtigkeit, ...

**Korrelierte Variablen weisen nicht  
immer eine direkte Kausalität aus!**

# Korrelierte Messgrößen



**Korrelierte Variablen weisen nicht  
immer eine direkte Kausalität aus!**

# Korrelierte Messgrößen

Wir betrachten die Funktion  $x = x^{(1)} + x^{(2)}$ , wobei  $x^{(1)}$  und  $x^{(2)}$  jeweils  $N$  mal gemessen wurden.

Welches Resultat erhalten wir für die Varianz von  $x$ ?

$$\begin{aligned} \text{var}(x) &= \frac{1}{N} \sum_{n=1}^N \left( x_n^{(1)} - \bar{x}^{(1)} + x_n^{(2)} - \bar{x}^{(2)} \right)^2 \\ &= \frac{1}{N} \sum_{n=1}^N \left[ \left( x_n^{(1)} - \bar{x}^{(1)} \right)^2 + \left( x_n^{(2)} - \bar{x}^{(2)} \right)^2 + 2 \left( x_n^{(1)} - \bar{x}^{(1)} \right) \left( x_n^{(2)} - \bar{x}^{(2)} \right) \right] \\ &= \text{var}(x^{(1)}) + \text{var}(x^{(2)}) + 2\text{cov}(x^{(1)}, x^{(2)}) \end{aligned}$$

# Korrelierte Messgrößen

Wir betrachten die Funktion  $x = x^{(1)} + x^{(2)}$ , wobei  $x^{(1)}$  und  $x^{(2)}$  jeweils  $N$  mal gemessen wurden.

Welches Resultat erhalten wir für die Varianz von  $x$ ?

Generell gilt:

Die  $a^{(k)}$  sind Konstanten

$$\text{var}\left(\sum_k a^{(k)} x^{(k)}\right) = \sum_k a^{(k)^2} \text{var}(x^{(k)}) + 2 \sum_{k < j} a^{(k)} a^{(j)} \text{cov}(x^{(k)}, x^{(j)})$$

**Für unkorrelierte Variablen ist die Varianz der Summe gleich der Summe der Varianzen**

# Korrelierte Messgrößen

- Korrelation kann durch die Kovarianz und den Korrelations-Koeffizienten dargestellt werden
- Korrelation beweist keine direkte Kausalität
- Die Interpretation von korrelierten Daten ist nicht immer einfach. Das zeigt sich u.a. exemplarisch in den Ernährungswissenschaften und der Medizin.

# Die Auto-Kovarianz

$$\sigma_{xy}^2 = cov(x, y) = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})(y_n - \bar{y})$$

$y = x$



$$cov(x, x) = \frac{1}{N-1} \sum_{n=1}^N (x_n - \bar{x})^2 = var(x) = \sigma_x^2$$



$y = x_{i+\Delta}$

$$R_{xx}(\Delta) = \frac{1}{N-\Delta} \sum_{n=1}^{N-\Delta} (x_n - \bar{x})(x_{n+\Delta} - \bar{x})$$

Diskrete Auto-Kovarianz

$$\rho_{xx} = \frac{R_{xx}(\Delta)}{\sigma_x^2}$$

$\in [-1, 1]$

Autokorrelations-  
koeffizient

$\tau = \Delta \times \Delta_t$

$$R_{xx}(\tau) = \frac{1}{N-\Delta} \sum_{t=t_1}^{t_N-\tau} (x(t) - \bar{x})(x(t+\tau) - \bar{x})$$

Diskrete Auto-Kovarianz

$$\rho_{xx} = \frac{R_{xx}(\tau)}{\sigma_x^2}$$


$\in [-1, 1]$

$$R_{xx}(\tau) = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T x(t) x(t+\tau) dt = \langle x(t) x(t+\tau) \rangle$$




Kontinuierliche Auto-Kovarianz

Nicht relevant für echte Daten – der Messvorgang führt immer zu diskreten Werten

# Die Auto-Kovarianz



Auto-Kovarianz



# Die Auto-Kovarianz


- Die Auto-Kovarianz ist symmetrisch um  $\tau = 0$
- Die Samplingzeit  $\Delta_t$  setzt ein unteres Limit für die zeitliche Auflösung der Auto-Kovarianz
- Ein Signal kann auf langen und kurzen Zeitskalen sehr unterschiedlich aussehen.



# Anwendung der Auto-Kovarianz in ultraschneller Optik


Beispiele aus der Vorlesung «Ultrafast Laser Physics» von Lukas Gallmann, ETH Zürich  
Und dem Buch «*Ultrafast Lasers*» von Ursula Keller

- Was ist Ultrafast Laser Optics?
- Welches Problem taucht bei der Charakterisierung ultraschneller Laserpulse auf?




# Anwendung der Auto-Kovarianz in ultraschneller Optik

Beispiele aus der Vorlesung «Ultrafast Laser Physics» von Lukas Gallmann, ETH Zürich  
Und dem Buch «*Ultrafast Lasers*» von Ursula Keller




$$I_{2\omega}(\tau) \propto \int_{-\infty}^{+\infty} I(t)I(t - \tau)dt$$




Sutter et al.: *Spektrum der Wissenschaft*,  
Dossier: Laser (1998)

# Anwendung der Auto-Kovarianz in ultraschneller Optik

Beispiele aus der Vorlesung «Ultrafast Laser Physics» von Lukas Gallmann, ETH Zürich  
Und dem Buch «*Ultrafast Lasers*» von Ursula Keller



Auto-Kovarianz



Siehe: Science 286, 1507 (1999)